



Documentação da Inteligência Preditiva

Sistema FarmTech Solutions: Modelo de Regressão para Produtividade e Irrigação

Integrantes do Grupo

- Arthur Prudêncio Soares (RM569295)
- Caroline Coelho Mendes (RM570370)
 - Leandro Paiva (RM572159)
- Lucas Viana de Lima (RM571835)
- Matheus Tavares Lima (RM572808)

Faculdade de Informática e Administração Paulista (FIAP)

Algoritmo: Regressão Linear Múltipla (Scikit-Learn) - **Linguagem:** Python

Banco de Dados: Oracle Database (via Docker)

Sumário

Visão Geral.....	3
1. Variáveis do Modelo (Dicionário de Dados).....	4
2. Pipeline de Machine Learning com Scikit-Learn.....	6
2.1 Divisão dos Dados (Treino e Teste).....	6
2.2 Configuração e Treinamento do Modelo.....	6
3. Métricas de Avaliação e Desempenho.....	7
4. Integração Visual com o Dashboard Streamlit.....	8
5. Justificativa da Escolha do Algoritmo.....	9

Faculdade de Informática e Administração Paulista (FIAP)

Algoritmo: Regressão Linear Múltipla (Scikit-Learn) - **Linguagem:** Python

Banco de Dados: Oracle Database (via Docker)

Visão Geral

No agronegócio moderno, a busca por eficiência operacional e sustentabilidade exige que a tomada de decisão deixe de ser puramente intuitiva. Fatores ambientais e do solo, como variações bruscas de umidade e desequilíbrios de pH, impactam diretamente o rendimento final das culturas. Sem uma análise preditiva centralizada, gestores enfrentam dificuldades para antecipar necessidades de irrigação e manejo, resultando em desperdício de recursos hídricos ou perdas severas na produtividade do campo.

Para mitigar esses problemas e dar início à Agricultura Cognitiva, o assistente **FarmTech Solutions** utiliza modelos de Inteligência Artificial baseados em aprendizado supervisionado (Regressão). O sistema transforma variáveis capturadas no campo em previsões numéricas exatas: o volume ideal de irrigação necessário e a estimativa de produtividade da safra. Este documento detalha o funcionamento do modelo, a infraestrutura de dados em container, o pipeline de Machine Learning implementado e os critérios de validação das métricas de erro.

1. Variáveis do Modelo (Dicionário de Dados)

O ecossistema consome 5 variáveis preditivas (*features*) capturadas por sensores de campo para estimar dois alvos numéricos contínuos em tempo real. Os dados extraídos do banco de dados relacional seguem a estrutura abaixo:

Variável	Tipo de Dado	Origem	O que representa
umidade_solo	NUMERIC(10,2)	Sensor de Solo	Percentual de umidade atual do solo (0 a 100%).
ph_solo	NUMERIC(10,2)	Sensor de Solo	Escala de pH do solo monitorado (0 a 14).
nivel_n	INTEGER	Sensor NPK	Presença de Nitrogênio detectada no solo (0 ou 1).
nivel_p	INTEGER	Sensor NPK	Presença de Fósforo detectada no solo (0 ou 1).
nivel_k	INTEGER	Sensor NPK	Presença de Potássio detectada no solo (0 ou 1).
volume_irrigacao_litros	NUMERIC(10,2)	Variável-Alvo 1	Volume de água recomendado em litros para manejo.
produtividade_kg	NUMERIC(10,2)	Variável-Alvo 2	Estimativa de rendimento final da safra em quilogramas.

Base de Dados e Persistência Relacional

O modelo foi inicialmente homologado com um conjunto de dados simulado de 100 registros gerados com semente fixa (`seed(42)`) para garantir a reprodutibilidade dos testes. Esses dados foram injetados no banco de dados **Oracle SQL** hospedado em um container **Docker**, estruturando tabelas tipadas que garantem a integridade relacional exigida pela disciplina de *Cognitive Data Science*.

Faculdade de Informática e Administração Paulista (FIAP)

Algoritmo: Regressão Linear Múltipla (Scikit-Learn) - Linguagem: Python

Banco de Dados: Oracle Database (via Docker)

Connections: FIAP, Oracle_Local-3, HISTORICO_AGRICOLA1, Oracle_Local

Worksheet: Query Builder

SELECT * FROM historico_agricola

Query Result: Fetched 50 rows in 0.13 seconds

	UMIDADE_SOLO	PH_SOLO	NIVEL_N	NIVEL_P	NIVEL_K	VOLUME_IRRIGACAO_LITROS	PRODUTIVIDADE_KG
1	54,98	5,08	1	0	0	58,03	59,9
2	78,83	6,59	1	0	1	22,02	81,99
3	69,28	5,79	0	0	1	25,81	66,98
4	63,95	6,27	0	1	1	38,36	66,68
5	46,24	7,27	1	0	0	54,75	57,02
6	46,24	5,62	1	0	0	58,76	58,28
7	42,32	6,03	1	1	0	58,03	69,16
8	74,65	6,89	1	0	1	23,43	72,06
9	64,04	5,57	1	1	1	36,52	73,97
10	68,32	5,19	1	1	1	34,99	76,55
11	48,82	5,72	0	0	0	67,11	21,24
12	78,8	5,4	1	1	1	15,01	82,58
13	73,3	7,32	1	0	1	37,37	72,5
14	48,49	7,02	0	1	1	41,75	59,04
15	47,27	6,58	0	1	1	51,07	58,51
16	47,34	7,18	0	0	0	55,61	47,41
17	52,17	7,01	0	1	0	49,24	54,86
18	68,99	5,47	1	1	1	35,9	73,54
19	57,28	7,23	1	1	0	41,68	63,61
20	51,65	6,35	1	1	0	45,89	65,98
21	64,47	7,02	1	1	1	32,58	74,67
22	45,58	7,24	1	0	1	58,67	71,43
23	51,69	5,8	1	1	0	58,1	68,33
24	54,65	5,28	0	0	1	41,88	45,53
25	58,24	5,57	1	1	0	46,26	56,7
26	71,41	6,07	0	0	1	38,13	64,61
27	47,99	7,05	0	0	0	56,08	37,51
28	68,57	7,15	1	1	1	42,58	85,78
29	63,7	5,02	0	1	0	32,16	43,91
30	41,86	6,28	1	1	0	55,34	55,49
31	64,3	6,04	0	0	0	39,43	44,26
32	46,82	5,56	1	1	1	56,23	69,76

Reports: All Reports, About Your Database, All Objects, Analytic View Reports, Application Express, ASH and AWR, Database Administration, Data Dictionary, Data Dictionary Reports, Data Modeler Reports, OLAP Reports, PLSQL, Security, Streams, Table, TimesTen Reports, User Defined Reports, XML

Line 1 Column 33 | Insert | Modified | Unix/Mac: LF

Faculdade de Informática e Administração Paulista (FIAP)

Algoritmo: Regressão Linear Múltipla (Scikit-Learn) - Linguagem: Python

Banco de Dados: Oracle Database (via Docker)

2. Pipeline de Machine Learning com Scikit-Learn

O algoritmo escolhido para o assistente preditivo foi a **Regressão Linear Múltipla** (**LinearRegression**), modelando matematicamente a relação linear entre as múltiplas variáveis de entrada dos sensores e as respostas contínuas de produção e manejo.

2.1 Divisão dos Dados (Treino e Teste)

Para garantir que o modelo seja capaz de generalizar o aprendizado em cenários reais e não apenas decorar o histórico (evitando o *overfitting*), a base de dados foi dividida utilizando a proporção clássica de **80% para treinamento** e **20% para testes independentes**:

Python

```
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)
```

Esta separação assegura a validação estatística em dados que o algoritmo nunca viu antes de ir para a produção no painel do gestor.

2.2 Configuração e Treinamento do Modelo

O pipeline instancia e treina simultaneamente duas vertentes preditivas isoladas a partir da mesma leitura de sensores:

Python

```
modelo_produtividade = LinearRegression()  
modelo_produtividade.fit(X_train, y_train_produtividade)
```

```
modelo_irrigacao = LinearRegression()  
modelo_irrigacao.fit(X_train, y_train_irrigacao)
```


3. Métricas de Avaliação e Desempenho

A validação do pipeline de inteligência artificial ocorre por meio do cálculo de quatro métricas consagradas de regressão sobre o conjunto de teste. No dashboard, o modelo obteve os seguintes resultados de aderência para a previsão de produtividade:

- **MAE (Erro Médio Absoluto): 4.43** – Indica que as previsões do assistente erram, em média, apenas 4.43 kg em relação ao valor real de campo, mostrando alta precisão de aproximação linear.
- **MSE (Erro Quadrático Médio): 28.48** – Métrica que penaliza erros de maior magnitude ao elevá-los ao quadrado. Útil para identificar desvios bruscos fora do padrão.
- **RMSE (Raiz do Erro Quadrático Médio): 5.34** – Retorna o desvio padrão dos resíduos para a mesma unidade da variável original (kg), confirmando a estabilidade das previsões.
- **R^2 Score (Coeficiente de Determinação): 0.86** – Mostra que **86% da variabilidade** da produtividade da safra é explicada e prevista com sucesso pelas variáveis de umidade, pH e nutrientes (NPK) passadas pelos sensores.

4. Integração Visual com o Dashboard Streamlit

Os resultados preditivos e a inteligência do modelo foram embarcados em uma interface interativa web desenvolvida em **Streamlit**. O sistema consome a tabela diretamente do Oracle via conector **oracledb**, trata a formatação das colunas e exibe um mapa de calor dinâmico contendo as correlações lineares entre os dados capturados.



O dashboard permite que o gestor atue em duas frentes:

1. **Visão Analítica:** Monitoramento dos erros do modelo estatístico e avaliação visual das tendências por correlação de Pearson (onde se observa, por exemplo, a forte correlação inversa de -0.95 entre a umidade do solo e a necessidade de volume de irrigação).
2. **Manejo Automatizado:** Utilizando controles deslizantes (*sliders*), o operador simula as condições atuais da plantação. O modelo processa as variáveis em milissegundos e retorna decisões automatizadas na tela através de alertas dinâmicos de negócio (ex: acionamento imediato de bombas d'água com a litragem exata calculada pela IA ou alertas críticos de correção de pH para o cultivo de milho).

Faculdade de Informática e Administração Paulista (FIAP)

Algoritmo: Regressão Linear Múltipla (Scikit-Learn) - Linguagem: Python

Banco de Dados: Oracle Database (via Docker)

5. Justificativa da Escolha do Algoritmo

A escolha da **Regressão Linear Múltipla** se justifica pelos seguintes pilares de engenharia e negócios:

- **Baixa Latência e Eficiência de Borda:** Por se tratar de um modelo puramente matemático baseado em coeficientes lineares, ele executa localmente sem a necessidade de infraestrutura pesada em nuvem ou placas aceleradoras de hardware (GPUs). É ideal para operação ágil em computadores modestos de fazendas ou servidores locais.
- **Explicabilidade Técnica:** Diferente de modelos complexos do tipo "caixa-preta" (como Redes Neurais), a regressão linear fornece coeficientes claros para cada variável. Isso permite que agrônomos auditem as regras do algoritmo e compreendam o peso exato de cada nutriente ou ponto percentual de umidade no resultado final.
- **Adequação Física ao Problema:** Relações no campo — como a perda de umidade necessitando proporcionalmente de mais litros de água na irrigação — se comportam de forma predominantemente linear. O modelo captura essa física com precisão e simplicidade, entregando um coeficiente R^2 elevado (0.86) sem complexidade computacional desnecessária.